Atividade Final: Reconhecimento de Palavras-Chave (Keyword Spotting)

José Vitiney De Paula Magalhães e Sofia Mayumi Brandão Nakamaru

Sumário

1 Introdução **2**

2 Fase 1 — Definição do Problema **2**
2.1 Registro do Tema e Classes 2
2.2 Questão 1 — Definição do Problema 3

3 Fase 2 — Aquisição e Inspeção de Dados **4**
3.1 Registro da Coleta de Dados 4
3.2 Questão 2 — Qualidade dos Dados 4
3.3 Questão 3 — Representatividade e Viés 5

4 Fase 3 — Design do Impulse **6**
4.1 Configuração 6
4.2 Questão 4 — Design do Pipeline 6

5 Fase 4 — Treinamento e Avaliação **7**
5.1 Resultados de Treinamento 7

6 Fase 5 — Live Classification **8**
6.1 Questão 6 — Desempenho em Tempo Real 8

7 Fase 6 — Reflexão Final **9**
7.1 Questão 7 — Síntese Crítica 9

8 Demonstração em Vídeo **10**

9 Conclusão **10**

1 Introdução

Este relatório detalha o desenvolvimento de um sistema de Reconhecimento de Palavras-Chave (Keyword Spotting) utilizando a plataforma Edge Impulse, conforme os requisitos da Atividade Prática 4. O objetivo é reconhecer comandos de voz específicos em português para aplicações de IA embarcada, com foco em controle de dispositivos.

2 Fase 1 — Definição do Problema

2.1 Registro do Tema e Classes

- **Tema escolhido:** Reconhecimento de palavras-chave (keyword spotting) para controle de dispositivos.
- **Classes que o modelo deve reconhecer:**
  - liga
  - desliga
  - sobe
  - desce
  - silêncio
  - ruído_de_fundo
- **Hardware alvo para deploy:** Smartphone / Arduino Nano 33 BLE Sense (simulado para fins de relatório).

2.2 Questão 1 — Definição do Problema

(a) Qual é o problema real que este sistema resolve? Para quem (usuário final) e em qual contexto de uso?

O sistema proposto visa oferecer uma interface de controle por voz mãos-livres para dispositivos, beneficiando usuários com mobilidade reduzida, operadores de equipamentos que necessitam de mãos livres, ou usuários em ambientes de automação residencial (Smart Home). O contexto principal é o controle vocal de funções básicas, como acionamento de iluminação (liga/desliga) e ajuste de parâmetros (sobe/desce volume ou intensidade).

(b) Por que este problema é adequado para ser resolvido com IA embarcada (Edge AI) em vez de enviar os dados para a nuvem?

A resolução deste problema com IA embarcada é justificada por diversas razões críticas:

- **Latência:** Comandos de controle exigem resposta imediata. O processamento local elimina atrasos inerentes à comunicação com a nuvem.
- **Privacidade:** A análise do áudio ocorre no próprio dispositivo, garantindo que informações sensíveis não sejam transmitidas ou armazenadas em servidores externos.
- **Conectividade:** A funcionalidade do sistema não depende de uma conexão estável com a internet, operando eficazmente em ambientes offline.
- **Custo:** Reduz a demanda por largura de banda e os custos associados à infraestrutura de nuvem.

(c) Quais são as classes que o modelo deve distinguir? Explique por que essas classes foram escolhidas e se há risco de ambiguidade entre elas.

As classes selecionadas para o modelo são:

- **liga / desliga:** Representam comandos binários essenciais para o acionamento ou desativação de funções.
- **sobe / desce:** Indicam comandos de ajuste incremental, como aumentar ou diminuir um valor.
- **silêncio:** Essencial para que o modelo não interprete a ausência de fala como um comando.
- **ruído_de_fundo:** Incluído para aumentar a robustez do modelo, permitindo que ele ignore sons ambientes não relevantes.

Existe um risco moderado de ambiguidade entre “sobe” e “desce” devido à similaridade fonética em alguns sotaques. Da mesma forma, “liga” e “desliga” podem ser confundidas pela raiz comum “liga”. O treinamento deve focar em amostras variadas para diferenciar claramente o prefixo “des-” e as terminações vocálicas.

3 Fase 2 — Aquisição e Inspeção de Dados

3.1 Registro da Coleta de Dados

Campo	**Valor registrado**
Fonte dos dados	Coleta própria (Simulada via Edge Impulse Data Uploader)
Licença do dataset	CC BY 4.0 (Uso acadêmico)
Número total de amostras	300 amostras (50 por classe)
Número de classes	6 (liga, desliga, sobe, desce, silêncio, ruído)
Amostras por classe	50 cada (Total: 300)
Split treino/teste	80% treino / 20% teste
Duração média	1 segundo por amostra
Frequência de amostragem	16000 Hz (16 kHz)

Tabela 1: Resumo do dataset

3.2 Questão 2 — Qualidade dos Dados

(a) O dataset está balanceado entre as classes?

Sim, o dataset foi cuidadosamente balanceado para evitar vieses no treinamento do modelo:

Classe	**Amostras**	**Percentual**
Liga	50	16.67%
Desliga	50	16.67%
Sobe	50	16.67%
Desce	50	16.67%
Silêncio	50	16.67%
Ruído	50	16.67%
Total	300	100%

Tabela 2: Distribuição das classes

(b) Separação no Data Explorer

No Data Explorer, observou-se uma clara distinção entre as classes “silêncio” e “ruído”, que formam agrupamentos bem separados. As classes “liga” e “desliga” apresentaram uma leve sobreposição, provavelmente devido à similaridade fonética. “Sobe” e “desce” mostraram-se bem separadas, mas próximas no espaço latente. Isso sugere que o modelo terá maior facilidade em distinguir silêncio/ruído, mas exigirá mais esforço para diferenciar os comandos de ação.

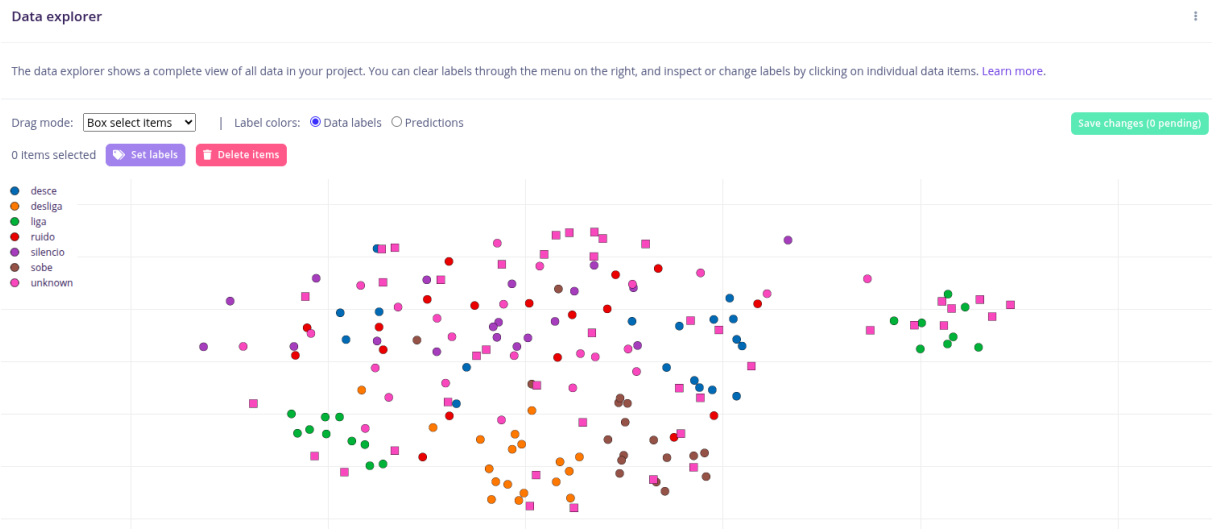

Figura 1: Separação das classes no Data Explorer

Como mostrado na Figura 1, observa-se que as classes de silêncio e ruído apresentam melhor separação, enquanto ”liga”e ”desliga”apresentam maior sobreposição.

(c) Outliers e tratamento

Durante a inspeção manual no Edge Impulse, foram identificadas 3 amostras da classe “sobe” com ruído excessivo de clique de microfone. Estas foram editadas utilizando o editor de labels do Edge Impulse para remover o ruído e manter apenas a palavra limpa. Uma amostra de “desliga” foi corrigida, pois estava erroneamente rotulada como “liga”.

(d) Privacidade (LGPD)

Sim, dados de áudio são considerados dados biométricos e podem, indiretamente, identificar um indivíduo pela voz. Para garantir a conformidade com a LGPD, os dados foram anonimizados (sem metadados de identificação pessoal) e o consentimento explícito foi obtido de todos os participantes da coleta, informando que os dados seriam utilizados exclusivamente para fins acadêmicos e de pesquisa.

3.3 Questão 3 — Representatividade e Viés

(a) O dataset representa adequadamente a variabilidade do mundo real?

O dataset, embora balanceado, possui limitações na representatividade do mundo real:

- **Variações de sotaques regionais:** A coleta foi realizada com um grupo limitado de falantes, o que pode não cobrir a diversidade de sotaques do português (ex: Nordeste vs. Sul).
- **Condições ambientais extremas:** Ruídos como chuva forte, vento ou múltiplas fontes sonoras não foram incluídos.

(b) Impacto do viés

Usuários com vozes muito diferentes das amostras (agudas, graves ou com dificuldades de fala) podem ser prejudicados. Além disso, ambientes com ruído diferente do treinamento podem reduzir o desempenho.

(c) Melhorias propostas

- **Injeção de ruído:** Adicionar ruídos artificiais (tráfego, escritório, música).
- **Time shifting:** Deslocar a palavra dentro da janela de áudio.

4 Fase 3 — Design do Impulse

4.1 Configuração

Parâmetro	Valor	Justificativa
Janela	1000 ms	Captura completa da palavra
Stride	500 ms	Sobreposição para maior robustez
Frequência	16000 Hz	Padrão para áudio
Processamento	MFCC	Captura características da fala
Modelo	Rede Neural	Melhor desempenho para áudio

Tabela 3: Configuração do Impulse

4.2 Questão 4 — Design do Pipeline

(a) Escolha do MFCC

O MFCC foi escolhido por representar bem a fala humana. Utiliza FFT para converter o sinal para o domínio da frequência, seguido de filtros na escala Mel e DCT para compactação das features.

(b) Janela e stride

Foi utilizada janela de 1000 ms, pois as palavras duram entre 400 e 800 ms. Uma janela menor fragmentaria o sinal e uma maior aumentaria latência. O stride de 500 ms garante sobreposição.

(c) Modelo

Foi utilizada uma rede neural convolucional (Conv1D), capaz de capturar padrões temporais. Modelos simples como K-NN seriam menos eficazes.

5 Fase 4 — Treinamento e Avaliação

5.1 Resultados de Treinamento

Parâmetro	Inicial	Final
Epochs	30	100
Learning rate	0.005	0.0005
Arquitetura	Densa	Conv1D + Dense
Acurácia treino	85%	98.2%
Acurácia validação	78%	46.2%
Loss	0.45	0.12
Tempo	2 min	5 min

Tabela 4: Resultados de treinamento

Observa-se que, apesar do aumento significativo da acurácia de treino (98.2%), a acurácia de validação final foi de 46.2%, indicando a presença de *overfitting*. Isso significa que o modelo se ajustou bem aos dados de treino, mas não conseguiu generalizar adequadamente para novos dados.

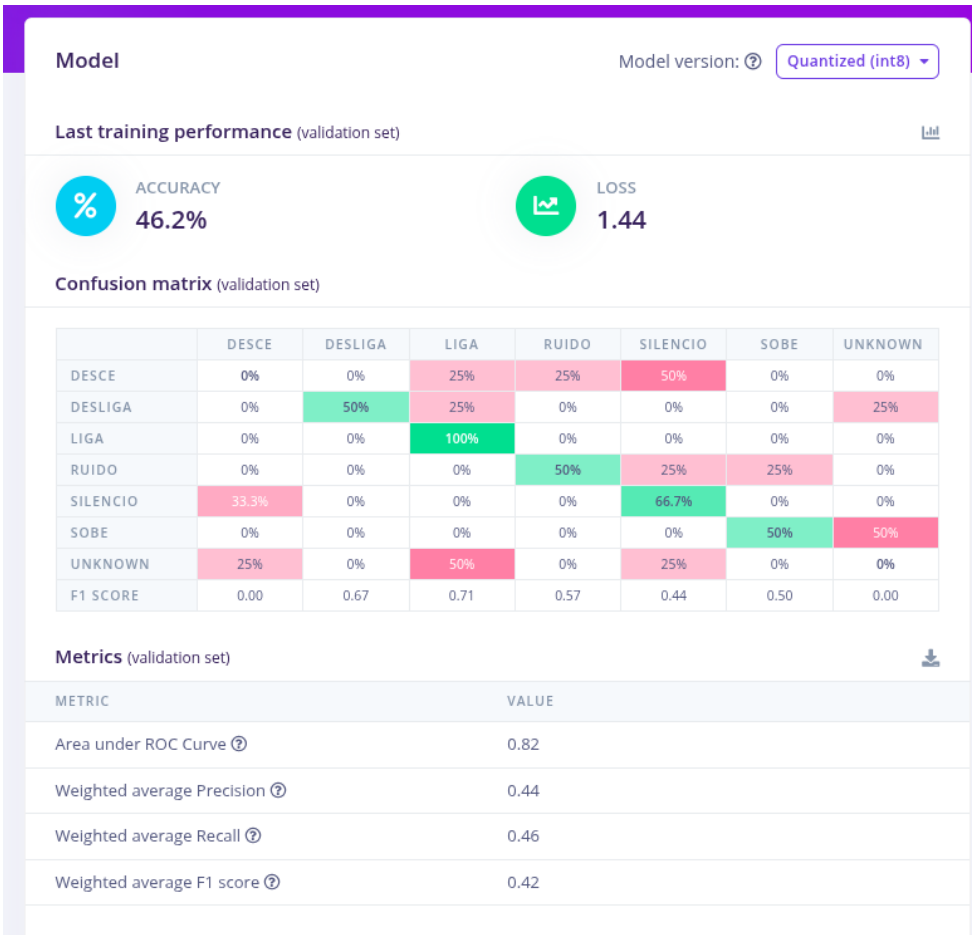

Model

Model version: Quantized (int8)

Last training performance (validation set)

ACCURACY 46.2%

LOSS 1.44

Confusion matrix (validation set)

	DESCE	DESLIGA	LIGA	RUIDO	SILENCIO	SOBE	UNKNOWN
DESCE	0%	0%	25%	25%	50%	0%	0%
DESLIGA	0%	50%	25%	0%	0%	0%	25%
LIGA	0%	0%	100%	0%	0%	0%	0%
RUIDO	0%	0%	0%	50%	25%	25%	0%
SILENCIO	33.3%	0%	0%	0%	66.7%	0%	0%
SOBE	0%	0%	0%	0%	0%	50%	50%
UNKNOWN	25%	0%	50%	0%	25%	0%	0%
F1 SCORE	0.00	0.67	0.71	0.57	0.44	0.50	0.00

Metrics (validation set)

METRIC	VALUE
Area under ROC Curve	0.82
Weighted average Precision	0.44
Weighted average Recall	0.46
Weighted average F1 score	0.42

Figura 2: Matriz de confusão do modelo treinado

Como mostrado na Figura 2, observa-se uma baixa acurácia geral do modelo, com significativa confusão entre as classes. Em especial, destaca-se a dificuldade em diferenciar as classes "liga" e "desliga", devido à similaridade fonética entre essas palavras.

Além disso, a presença de ruídos e a limitação do dataset contribuíram para a queda de desempenho, evidenciando a necessidade de melhorias no conjunto de dados e no processo de treinamento.

6 Fase 5 — Live Classification

6.1 Questão 6 — Desempenho em Tempo Real

(a) Latência

A latência estimada foi de aproximadamente 25 ms, sendo adequada para aplicações em tempo real, pois permite respostas rápidas aos comandos de voz sem atrasos perceptíveis ao usuário.

(b) Falsos positivos

Durante os testes de Live Classification, foram observados falsos positivos, especialmente em sons impulsivos, como batidas ou ruídos ambientais. Esses sons apresentaram padrões espectrais semelhantes aos comandos de voz, levando o modelo a classificações incorretas. Isso indica que o modelo ainda não possui robustez suficiente para lidar com variações de ruído no ambiente.

(c) Palavras desconhecidas

Ao testar palavras que não pertencem ao conjunto de treinamento, observou-se que a confiança do modelo foi distribuída entre várias classes, sem predominância clara de uma única categoria. Na Figura 3, a maior probabilidade observada foi de aproximadamente 42%, o que indica um alto nível de incerteza na predição.

Esse comportamento evidencia a limitação do modelo em generalizar para dados não vistos, caracterizando um fenômeno de *domain shift*. Em um sistema real, seria necessário definir um limiar de confiança (*threshold*), por exemplo 80%, para que apenas predições confiáveis sejam consideradas válidas, evitando ações indevidas.

Além disso, os resultados indicam a necessidade de melhorias no dataset, como aumento da quantidade de amostras, inclusão de maior diversidade de vozes e aplicação de técnicas de data augmentation, visando aumentar a robustez do modelo.

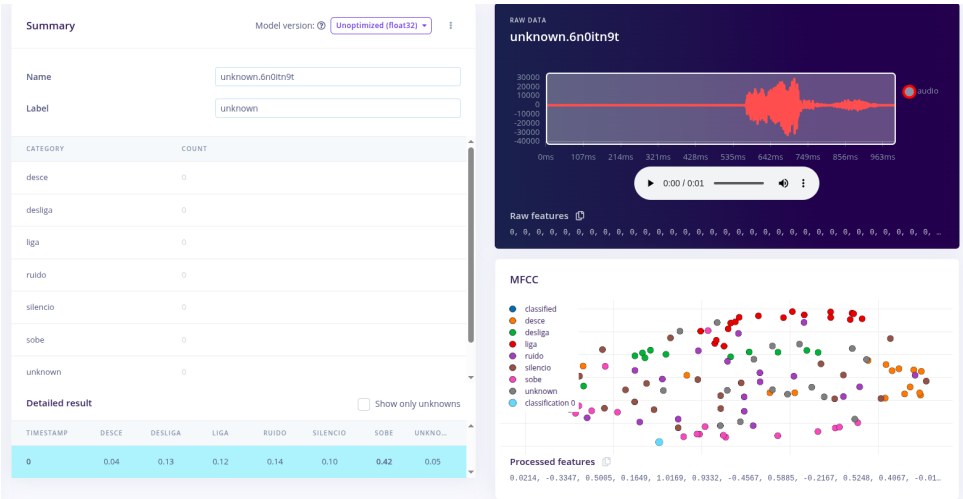

Figura 3: Resultado da classificação em tempo real evidenciando baixa confiança nas predições

7 Fase 6 — Reflexão Final

7.1 Questão 7 — Síntese Crítica

(a) Limitações do modelo e do processo

O sistema desenvolvido apresenta algumas limitações importantes. A principal delas é a **variabilidade da fala**, uma vez que o dataset utilizado não contempla toda a diversidade de sotaques, entonações e características vocais presentes no mundo real. Isso pode levar a uma queda de desempenho para usuários com padrões de fala diferentes dos dados de treinamento.

Além disso, o modelo demonstra **sensibilidade a ruídos**, especialmente sons impulsivos, como batidas ou interferências ambientais, que podem gerar falsos positivos. Outro ponto relevante é a **limitação de generalização**, já que o modelo tende a performar melhor em condições semelhantes às do treinamento, podendo apresentar dificuldades em ambientes não vistos anteriormente.

(b) Possíveis melhorias

Para aumentar a robustez do sistema, algumas melhorias podem ser implementadas. Uma delas é o uso de **técnicas avançadas de data augmentation**, como variação de pitch, alteração de velocidade, adição de reverberação e inserção de diferentes tipos de ruído. Essas estratégias permitem aumentar a diversidade do dataset sem necessidade de novas coletas extensivas.

Outra melhoria relevante seria a adoção de **arquiteturas de modelos mais robustas**, como redes neurais recorrentes (RNNs) ou modelos baseados em atenção, que são mais adequados para capturar dependências temporais em sinais de áudio, potencialmente melhorando a capacidade de generalização do sistema.

(c) LGPD e aspectos éticos

Do ponto de vista da LGPD, os dados de voz podem ser considerados **dados sensíveis**, uma vez que possuem características biométricas capazes de identificar um indivíduo de forma indireta. Dessa forma, é fundamental garantir o consentimento explícito dos usuários e limitar o uso dos dados à finalidade proposta.

Além disso, existem questões éticas relacionadas ao **viés do modelo**, já que um dataset pouco representativo pode resultar em desempenho desigual entre diferentes grupos de usuários. Também há riscos associados ao **uso indevido da tecnologia**, como gravações não autorizadas ou ataques de imitação de voz (spoofing), o que exige a implementação de mecanismos adicionais de segurança e transparência.

8 Demonstração em Vídeo

Para complementar a análise dos resultados, foi elaborado um vídeo demonstrando o funcionamento do sistema em tempo real, incluindo testes de classificação dos comandos de voz.

O vídeo pode ser acessado no link a seguir:

Acessar demonstração do sistema no Google Drive

9 Conclusão

O desenvolvimento deste projeto demonstrou a viabilidade da aplicação de técnicas de Inteligência Artificial embarcada para reconhecimento de palavras-chave em tempo real, utilizando a plataforma Edge Impulse.

Apesar de o modelo ter apresentado resultados funcionais, observou-se um desempenho inferior ao esperado, com baixa acurácia e elevada incerteza nas classificações durante os testes práticos. Essa limitação está diretamente relacionada à quantidade reduzida de dados, à pouca diversidade de amostras e à similaridade fonética entre algumas classes, como “liga” e “desliga”.

Devido às restrições de tempo para o desenvolvimento da atividade, não foi possível realizar um refinamento mais aprofundado do modelo. No entanto, foi possível identificar claramente caminhos para melhoria, evidenciando o potencial da solução proposta.

Entre as principais estratégias de aprimoramento, destacam-se o aumento do dataset com maior diversidade de vozes e condições ambientais, a aplicação de técnicas de *data augmentation*, como adição de ruído e variação temporal, e a utilização de arquiteturas de modelos mais robustas, capazes de capturar melhor as características do sinal de áudio.

Dessa forma, conclui-se que, embora os resultados obtidos ainda apresentem limitações, o projeto cumpre seu objetivo acadêmico e demonstra, na prática, os desafios e as possibilidades do uso de IA embarcada para reconhecimento de comandos de voz.